



综述

半导体器件建模从物理驱动到智能融合：综述与展望

作者一¹

1. 中国科学院微电子研究所, 北京 100029

E-mail: author1@email.com

收稿日期: 2026-06-14; 接受日期: 2026-06-20;

国家自然科学基金(批准号: 6xxxxxxx)资助项目

摘要 随着半导体工艺节点不断向纳米尺度微缩, 传统物理基紧凑模型面临参数提取复杂、可扩展性差及新物理效应建模困难等挑战。与此同时, 人工智能(AI)特别是机器学习(ML)技术的发展, 为器件建模提供了新的数据驱动解决方案。本文系统回顾了从 BSIM、EKV 等经典物理模型到人工神经网络(ANN)、卷积神经网络(CNN)、物理信息神经网络(PINN)及混合智能模型的演进历程, 重点分析了 AI 在参数自动提取、模型替代、变异性建模及设计技术协同优化(DTCO)中的应用现状与效果。通过对比不同方法在精度、效率、物理一致性及泛化能力等方面的表现, 揭示了纯数据驱动方法与物理融合方法各自的优势与局限。最后展望了融合物理先验与深度学习的下一代紧凑模型范式, 以及在全场景(从纳米逻辑到宽禁带功率)建模中的应用前景。

关键词 半导体器件, 紧凑模型, 人工智能, 机器学习, 物理信息神经网络, 参数提取, DTCO

PACS: 85.30.-z, 84.30.-r, 07.05.Mh

1 引言

半导体器件建模是连接工艺制造与电路设计的核心桥梁。其基本任务是建立能够准确描述器件电学行为(如电流-电压 I-V、电容-电压 C-V、温度特性、噪声特性等)且具备高仿真效率的紧凑模型(Compact Model), 供 SPICE 等电路仿真器使用。随着集成电路技术沿着摩尔定律不断推进, 器件结构从平面 MOSFET 发展到 FinFET、GAAFET、

纳米片 FET, 再到面向功率电子和射频应用的宽禁带半导体(SiC、GaN)及新兴二维材料器件, 建模的复杂度呈指数级增长。

传统物理基模型如 BSIM-CMG^[1,2] 和 EKV 模型^[3-5] 在过去数十年中支撑了集成电路产业的快速发展。然而, 随着器件尺寸进入 10 nm 以下节点, 量子效应、短沟道效应、热效应、可靠性效应等多物理场耦合问题日益突出, 传统模型面临以下严

引用格式: 作者一, 作者二, 作者三. 半导体器件建模从物理驱动到智能融合: 综述与展望. 中国科学: 物理学 力学 天文学, 2026, 66: XXXXXX, doi: 10.1360/SSPMA-2026-XXXX

Author A, Author B, Author C. From Physics-Driven to Intelligent Fusion in Semiconductor Device Modeling: A Review (in Chinese). Sci Sin-Phys Mech Astron, 2026, 66: XXXXXX, doi: 10.1360/SSPMA-2026-XXXX

峻挑战：首先是方程复杂度爆炸：为了描述新物理效应，模型方程动辄包含数百个经验参数，参数之间高度耦合，物理可解释性下降。其次参数提取困难：传统参数提取依赖专家手工迭代优化，耗时数周甚至数月，难以适应工艺快速迭代和 DTCO（设计技术协同优化）的需求。此外模型的可扩展性差：同一模型难以覆盖不同几何尺寸（栅长、栅宽、鳍数）、不同温度、不同工艺角下的器件行为。当出现全新器件结构或材料体系（如 β -Ga₂O₃、2D 材料 FET）时，从零开发物理模型周期过长。

近年来，人工智能（AI）尤其是机器学习（ML）技术的突破性发展，为上述挑战提供了全新的解决思路^[6-9]。机器学习方法擅长从高维数据中自动学习复杂映射关系，无需显式建模物理方程。这一特性使其在以下方面展现出巨大潜力。在参数自动提取方面，利用深度学习可直接从 I-V/C-V 曲线中预测模型参数，从而大幅缩短 PDK 开发周期。在模型替代方面，神经网络能够直接替代复杂的物理方程，在保证精度的同时将仿真速度提升一个数量级以上。此外，机器学习还可用于变异性与可靠性建模，通过学习工艺波动与器件电学特性之间的统计映射，支持良率分析与蒙特卡洛仿真。更为重要的是，以物理信息神经网络（PINN）为代表的方法能够统一处理电、热、力等多物理场耦合问题，从而突破传统解耦近似的局限。

本文旨在系统梳理半导体器件建模方法从纯物理驱动到数据驱动再到物理-数据融合的演进历程。与现有综述不同，本文重点强调：方法的纵向对比——从 BSIM 到 ANN、CNN、ResNet、PINN，清晰展示技术迭代路径；应用的横向覆盖——涵盖逻辑器件（FinFET、GAAFET）、功率器件（SiC、GaN、 β -Ga₂O₃）及新兴存储器（Z²-FET）等多类器件；工业落地的实际考量——结合 McAndrew 等人^[10]提出的 AI/ML 建模基准指南，评估各类方法的工业成熟度。文章结构如下：第 2 节回顾传统紧凑模型的发展与局限；第 3 节系统介绍 AI 驱动的各类建模方法；第 4 节聚焦面向先进器件的建模应用；第 5 节讨论模型验证与工业强度评估；第 6 节分析挑战与未来方向；第 7 节总结全文。

2 传统紧凑模型的发展与局限

2.1 BSIM 系列模型：从 BSIM3 到 BSIM-CMG

BSIM (Berkeley Short-channel IGFET Model) 系列模型由加州大学伯克利分校器件组开发，是工业界事实标准的 MOSFET 紧凑模型。BSIM3v3 和 BSIM4 系列成功支撑了从 0.35 μ m 到 28 nm 平面 CMOS 工艺的设计。随着 FinFET 在 22 nm 节点的商业化，BSIM-CMG (Common-Multi-Gate) 应运而生^[1]。

相较于前代模型，BSIM-CMG 的核心创新体现在三个方面。其一，统一 Fin 截面电荷计算方法支持梯形、三角形等多种 Fin 截面形状，能够精确计算周长相关的电荷分布。其二，模型引入了体偏置对阈值电压的调制机制，以及依赖于偏置的量子力学限制效应模型。其三，通过统一场穿透长度，BSIM-CMG 能够精确刻画短沟道效应对阈值电压和亚阈值摆幅的影响，从而支持 14 nm 及以下节点的 FinFET 建模。

Duarte 等人^[1]的工作表明，BSIM-CMG 成功捕捉了工业级 FinFET 的关键物理效应。何进等人^[2]系统总结了 BSIM 模型的发展历程及其在纳米尺度器件中的适用性。然而，BSIM-CMG 包含数百个经验参数，参数之间存在复杂的交叉耦合，其提取过程严重依赖人工经验与多次迭代优化，成为工艺开发中的瓶颈环节。

2.2 EKV 模型：弱反型区的优雅描述

与 BSIM 的参数密集型路径不同，EKV 模型（以 Enz、Krummenacher、Vittoz 三位开发者命名）走了一条截然不同的设计道路——它强调从弱反型到强反型区域的统一、连续描述。Enz^[5]回顾了 EKV 模型的演进历史：从 20 世纪 70 年代早期弱反型晶体管模型出发，逐步发展出具有层次化结构、参数精简且灵活度高的紧凑模型。

EKV 模型的核心优势体现在三个方面。其一，单一方程覆盖全区域：通过合适的插值函数，将弱反型的指数特性与强反型的平方律特性无缝衔接，消除了区域切换带来的不连续性。其二，对称性参考：

将所有电压参考到局部衬底, 天然满足源漏对称性要求, 避免了传统模型中人为的对称性校正。其三, 低功耗设计友好: 精确描述亚阈值区域行为, 使其特别适合超低功耗模拟与射频电路设计。

Enz 等人 [3] 详细推导了 EKV 模型的大信号、小信号、非准静态及热噪声表达式, 整个模型仅需 9 个物理参数、3 个精细拟合系数和 2 个温度参数。然而, EKV 模型在先进节点 (7 nm 以下) 中对短沟道效应、速度饱和、量子效应等描述能力有限, 逐渐被 BSIM-CMG 取代。但 EKV 的设计哲学——精简参数、物理透明——对今天的智能建模仍有重要启示: 在追求精度的同时, 不应忽视模型的简洁性与可解释性。

2.3 宽禁带功率器件模型: SiC 与 GaN 的特殊挑战

宽禁带半导体 (SiC、GaN) 因其高击穿场强、高电子饱和速度、高热导率等优异特性, 在新能源汽车、光伏逆变器、5G 射频等领域获得广泛应用。然而, 这些器件的物理特性给建模带来了传统硅器件不曾面临的特殊挑战。

以 SiC MOSFET 为例, 其导通电阻呈现非单调的温度依赖性——低温段随温度下降而降低, 高温段则随温度上升而升高——这要求模型必须精确刻画迁移率与界面陷阱的复杂交互 [11]。与此同时功率器件中的米勒电容 (C_{gd}) 随电压剧烈变化, 直接影响开关损耗的仿真精度, 而高功率密度下芯片内部高达 200 °C 以上的温升又迫使模型必须耦合电热效应 [12]。此外功率器件的封装 (TO-247、D2PAK 等) 引入显著的电感、电容、电阻, 必须在模型中包含。

针对上述挑战, 研究者从不同角度给出了回应。Kraus 和 Castellazzi [11] 提出了考虑界面陷阱电荷和迁移率依赖性的 SiC MOSFET 物理模型, 与 2D TCAD 仿真和实验数据吻合良好。Mudholkar 等人 [13] 进一步实现了基于数据手册参数提取的策略, 降低了用户门槛。Mukunoki 等人 [13, 14] 连续改进了 SiC MOSFET 紧凑模型, 新模型在瞬态波形 (V_{ds} 、 I_{ds} 、漏电流) 上与实测一致性显著提升。

对于 GaN HEMT, Jarndal 等人 [15] 采用遗传算法 (GA) 优化 ANN 初始权重, 成功建立了大信号模型, 并在 ADS 中实现。Swain 等人 [16] 针对 AlGaN/GaN MOSHEMT 的正向栅漏电流, 提出了陷阱辅助隧穿 (TAT) 与 Poole-Frenkel 发射的物理模型。

然而, 无论上述努力多么精巧, 传统建模路径始终面临一个根本性矛盾: 为了捕捉更多物理效应, 模型不得不引入越来越多的参数, 而参数的膨胀又使得提取过程愈发依赖专家经验、耗时冗长, 且校准后的模型往往只能适用于特定的工艺条件, 难以迁移到新结构或新材料上。正是这些局限——精度与复杂度之间的张力、对专家的依赖、对工艺变化的脆弱性、以及对新器件响应迟缓——驱动着研究者将目光投向了数据驱动方法。

3 AI 驱动的建模方法

根据 AI 在建模流程中的角色和与物理知识的融合程度, 本节将 AI 驱动的方法分为三类: 纯数据驱动模型 (第 3.1 节)、物理启发与混合模型 (第 3.2 节) 以及参数提取自动化 (第 3.3 节)。

3.1 纯数据驱动模型: 神经网络作为通用逼近器

人工神经网络 (ANN) 因其通用逼近能力, 被最直接地用于替代紧凑模型的解析方程。Wang 等人 [17] 系统评估了 ANN 架构在先进 FET 建模中的适用性, 提出了包含转换函数 (将 ANN 输出映射为终端电流/电荷) 和定制化损失函数的设计流程。他们的关键发现包括: 通过合理选择激活函数 (如 tanh、swish) 和输出层转换 (如指数函数确保电流正值), ANN 可高精度再现 I-V 和 C-V 特性; ANN 的大小需要在模型精度与 SPICE 仿真时间之间权衡, 可自动化生成最优架构; 通过模型重定位和变异性建模, ANN 还能扩展支持不同工艺角。

与 Wang 等人的工作形成互补, Wei 等人 [18] 在 0.18 μm 模拟工艺上对比了 ANN 模型与 BSIM4 模型。他们采用了一种不同的策略——通过对漏极电压和电流进行对数变换并配合拉丁超立方采样

(LHS), 显著减少了训练数据量。结果表明, ANN 模型在 I-V、跨导 (g_m)、输出电阻 (r_o) 的拟合精度上均优于 BSIM4, 且基于 ANN 构建的放大器与 LDO 在 DC 仿真中收敛良好。如果说 Wang 的关注点是“如何让 ANN 学习得更准”, 那么 Wei 的工作则揭示了“如何用更少的数据让 ANN 学得够好”。

Tung 和 Hu^[19] 则将注意力转向了模拟电路设计中至关重要的导数平滑性问题。他们提出的 NN-BSIM 框架包含漏、源、栅电流和电荷及其变异性, 训练数据由 BSIM 生成并覆盖沟道长度、宽度、氧化层厚度等几何参数范围。该框架的关键创新在于: 损失函数专门优化了电流和电荷导数的准确性, 并通过 Gummel 对称性测试、谐波平衡测试和环振仿真验证了模型的鲁棒性。这一工作提醒我们: 即使 I-V 拟合误差很小, 如果导数不光滑, 模型也无法用于实际电路设计。

卷积神经网络也能够用于图像化参数提取。一个独特的方向是将 I-V 曲线视为“图像”, 利用 CNN 从图像中提取电学参数。Bavi 和 Khandelwal^[20] 首次探索了这一思路: 他们利用 TCAD 生成了 500 个不同迁移率和功函数参数组合下的 SiC MOSFET I-V 曲线图像, 分别采用修改后的 ResNet18 和一个自定义的 6 层 CNN 进行训练, 以预测阈值电压 (V_{th})。结果显示, 自定义 CNN 取得了 MSE=0.05、每个 epoch 平均训练时间 22 秒的优异表现, 优于 ResNet18。这一工作的启示在于: 未来或许可以直接利用器件数据手册中的 I-V 曲线截图训练 AI 模型, 无需获取原始测量数据。

单一模型容易过拟合, 而集成策略可以有效缓解这一问题。Zhang 等人^[21] 针对 GAAFET 的电学特性预测, 提出了融合深度学习 (DL) 和机器学习 (ML) 的集成学习模型——同时使用神经网络和支持向量回归 (SVR) 等模型, 然后通过加权融合输出。在预测直流特性、电容特性和电学参数时, 该方法的线性回归决定系数 (R^2) 超过 0.99, RMS 误差极小, 证明了集成策略的价值。

纯数据驱动模型的优势在于无需物理假设、训练后推理极快、可灵活处理高维输入。但其局限性

同样突出: 外推不可靠 (超出训练范围可能输出非物理解)、不满足物理渐近性 (如饱和区电流应基本恒定)、难以保证导数平滑性。这些局限推动了物理知识与数据驱动的融合。

3.2 物理启发与混合模型

物理启发模型则试图在数据与物理规律之间寻求平衡。不同研究者给出了各具特色的答案, 包括物理启发神经网络 (Pi-NN)、物理信息神经网络 (PINN)、知识基神经网络 (KBNN) 等。

Li 等人^[22] 提出的 Pi-NN 框架, 核心思想是在神经网络结构中嵌入基本物理关系, 而非仅依赖数据拟合。具体包括: 通过输入变换 (如用 V_{ds} 和 V_{sd} 对称化) 强制满足源漏对称性; 在损失函数中加入对渐近区域 (如 $V_{ds} \rightarrow 0$ 时的线性区、 V_{ds} 很大时的饱和区) 的惩罚项; 以及确保 g_m 始终为正、 g_{ds} 在正常偏置下非负的单调性约束。Pi-NN 可以从离散数据点中学习得到平滑、准确且计算高效的器件模型, 同时避免了纯 ANN 常见的非物理振荡。

与 Pi-NN 的“软约束”不同, PINN 采取了更直接的方式——将物理方程 (如泊松方程、电流连续性方程) 作为残差项硬性加入损失函数, 使网络训练同时拟合数据并遵守物理规律。Lu 等人^[23] 将 PINN 应用于 Si 纳米线 TCAD 仿真预测, 展示了令人印象深刻的外推能力: 仅在亚阈值区数据上训练, 即可预测 2.5 倍于训练范围的电压区间, 并能推断出反型区特性。更关键的是, 该方法无需访问 TCAD 内部求解器, 也无需人工编写复杂的物理方程——物理信息模块本身也是从数据中学习的。这一工作为“数据驱动与物理驱动深度融合”开辟了新路径。

Yang 等人^[24] 针对宽温度范围 ($-50\text{ }^{\circ}\text{C}$ 至 $200\text{ }^{\circ}\text{C}$) 的 4H-SiC MOSFET, 提出了另一种混合思路: 用两个 ANN 分工协作。第一个 ANN 基于对称性修正的 BSIM 模型, 预测 I-V 曲线的主要趋势, 确保物理一致性和对称性; 第二个 ANN 则学习 BSIM 未覆盖的非理想因素 (如陷阱效应、接触电阻等) 的残差。这一设计的显著优势是: 仅需不到 30% 的训练数据即可达到纯 ANN 相同的精

度,且无需额外添加平滑函数即可保证导数连续性。在 SPICE 中对反相器和 NAND 逻辑电路的仿真显示,最大模型误差不超过 1.8%。

Qi 等人^[25]提出的 KBNN 方法在哲学上与双 ANN 相似,但实现路径不同:首先建立一个粗糙的物理模型作为“知识基底”,然后训练一个浅层 NN 来学习物理模型的残差。与纯 NN 相比,KBNN 需要更少的参数和训练数据,同时保持了物理模型的合理外推行为,尤其适合二维材料(如 MoS₂) FET 等数据稀缺场景。

上述混合方法虽然技术路径各异,但共同特点是“物理约束 + 数据拟合”。Pi-NN 强调结构嵌入, PINN 强调方程约束,双 ANN 和 KBNN 强调残差学习。相比于纯数据驱动,它们具备更好的外推性、导数平滑性和物理可解释性;相比于纯物理模型,它们更容易适应新工艺、新结构。这一方向被认为是通向工业级 AI 紧凑模型的最有希望路径。

3.3 参数提取自动化

前两类方法是在重新设计器件模型,那么参数提取自动化则是在“改进现有模型的生成方式”——这是传统建模中最耗时、最依赖人工经验的环节,也是 AI 最早产生实际影响的领域。

Kao 等人^[26]首次将深度学习应用于 BSIM-CMG 参数提取,思路直接而有效:通过 Monte Carlo 仿真生成 50k 组训练样本,以 C_{gg} - V_g 和 I_d - V_g 为输入、BSIM-CMG 参数为输出,训练深度神经网络。在 Intel 10 nm 节点校准的 TCAD FinFET 上测试, C_{gg} - V_g 拟合的 RMS 误差仅为 0.16%, I_d - V_g 拟合的 RMS 误差为 6.1% (亚阈值以上区域仅 0.69%)。更重要的是,对于栅长和氧化层厚度有 10% 波动的器件,训练好的 DL 模型仍然能够成功建模,证明了其对工艺波动的鲁棒性。

Kao 的工作聚焦于单一器件,而 Chavez 等人^[27]将参数提取扩展到了全局(多栅长)BSIM-

CMG 模型。他们生成了包含 300k 训练集、7.78 亿数据点的大规模数据,训练 DL 引擎预测模型参数。在 8 种不同栅长下,DL 提取的模型均表现出良好精度,成功再现了 I_{off} 、 I_{sat} 、 I_{lin} 以及 V_{th} 的可扩展性,显著减少了全局模型的提取时间。

Singhal 等人^[28]提出了一个值得关注的混合框架:先利用 BSIM-CMG 模型的可扩展性进行初步参数估计(物理初始化),再利用 DL 算法精化预测结果。该框架与 BSIM-CMG 无缝集成,可适用于 GAA 纳米片、纳米线 FET 和 FinFET 等多种先进器件,在 14 nm FinFET、12 nm 纳米片 FET 和 24 nm 纳米线 FET 的实验数据上均得到成功验证。这一思路的启示在于:物理知识与数据驱动并非对立,而是可以形成“粗估计 → 精校正”的互补关系。

GatedNN^[29]在传统 DL 参数提取基础上引入门控机制——对不同模型参数的梯度下降进行门控控制,有效解决了参数之间的优化冲突问题;同时结合参数重要性分析和模型质量检查,在 BSIM-CMG 模型和实测 FinFET 数据上实现了比之前最先进方法低 69% 的误差。

除了深度学习,经典优化算法也在参数提取中发挥作用。Liu 等人^[30]将 ANN 与人工蜂群算法(ABC)结合用于 SiC MOSFET 建模,改进的 ABC 算法帮助 ANN 找到更优的初始权重和偏置,解决了 Levenberg-Marquardt 方法对初始值敏感的问题。该混合方法在不同温度下的 I-V 拟合精度得到验证,且未暴露在训练中的小信号参数 g_m 和 g_d 也与数据手册高度吻合。

3.4 各方法综合对比

为便于直观理解上述各类方法的差异,表 1 从物理一致性、参数提取难度、外推能力、仿真速度和工业成熟度等维度进行了对比。

表 1 不同器件建模方法的对比

Comparison of different device modeling approaches

方法类型	代表工作	物理一致性	参数提取 难度	外推能力	仿真速度	工业成熟度
BSIM-CMG	Duarte ^[1]	高	高（专家 依赖）	好	基准	工业标准
EKV	Enz ^[3]	高	中	中	快	中等
纯 ANN	Wang ^[17]	低	低	差	非常快	实验室
CNN 图像提取	Bavi ^[20]	低	低	差	快	探索期
Pi-NN	Li ^[22]	中	中	中	快	实验室
PINN	Lu ^[23]	高（方程约 束）	低	好	中	探索期
GatedNN	Guo ^[29]	中	低	中	快	实验室/工业 转化
混合物理-ANN	Yang ^[24]	高	低	好	快	实验室

4 面向先进器件的建模

从逻辑器件到功率器件再到新兴存储器，不同器件类型对建模提出了差异化的挑战。AI 辅助建模方法在这些场景中的应用，既共享某些通用思路，也展现出针对特定器件特性的独特设计。

4.1 FinFET 与 GAAFET

FinFET 和 GAAFET 是先进逻辑节点的核心器件。BSIM-CMG 作为标准模型，已经支持从 FinFET 到 GAAFET 的建模^[1]。然而，随着纳米片 FET（NSFET）在 3 nm 及以下节点的采用，一个棘手的问题浮出水面：纳米片宽度、片数、片间距、栅极环绕角度等多个几何参数共同决定电学特性，导致传统的“维纳模型”（遍历所有参数组合）样本效率极低。

Jeong 等人^[31]针对 NSFET 提出了一个解决方案：多保真度模型（Multi-Fidelity Model）与主动学习策略。其核心思想是：少量高保真 TCAD 仿真（精确但昂贵）与大量低保真仿真（快速但精度较低）结合，利用主动学习算法智能选择信息量最大的仿真点，而非盲目地在全空间均匀采样。结果表明，在保持预测误差低于 1.5% 的前提下，所需 TCAD 仿真量减少了超过 50%。此外，简化后的 NN 模型还显著降低了 SPICE 仿真时间。这一工作的启示在于：在数据获取成本高昂的场景中，“怎

么选数据”和“怎么建模型”同样重要。Zhang 等人^[21]则采用了不同的策略——集成学习。他们同时使用神经网络和支持向量回归（SVR）等模型，然后通过加权融合输出。两种思路对比来看：Jeong 的方法侧重于减少数据需求，Zhang 的方法侧重于提升预测稳定性。二者并非互斥，未来或可结合——用主动学习选择数据点，用集成学习训练最终模型。

值得注意的是，Ruihan 和 Xingsheng^[32]的研究专注于纳米片晶体管紧凑模型的高效提取与生成，强调了紧凑模型作为连接工艺与设计桥梁的关键作用——这一观点在 DTCO（设计技术协同优化）背景下尤为重要。

4.2 宽禁带功率器件

如果说逻辑器件的建模难点在于“多几何参数”，那么功率器件的挑战则集中在“多物理场耦合”——温度、电场、热场三者交织，任何一个因素的忽略都可能导致仿真与实测的显著偏差。

SiC MOSFET 在电动汽车牵引逆变器等高温、高频应用中日益普及，其建模面临三重挑战：宽温度范围内的非单调导通电阻行为、随电压剧烈变化的非线性电容、以及高达 200 °C 以上的自热效应。针对这些挑战，不同研究者给出了不同深度的回应。Arribas 等人^[33]走的是极简物理路线——提出了仅需从静态 I-V 和 C-V 测量中提取少量参数的物理基精简模型，并在双向 buck-boost DC-DC 变换

器中完成验证。Kraus 和 Castellazzi^[11] 则更深入物理机制, 成功描述了界面陷阱电荷对沟道电荷和电子迁移率的影响。Mukunoki 等人^[13,14] 在前人基础上持续迭代, 使得改进模型在瞬态波形(包括散热器泄漏电流)上与实测数据取得了极好的一致性。如果说上述工作是“在物理框架内精益求精”, 那么 Liu 等人^[30] 的 ANN-ABC 混合模型和 Yang 等人^[24] 的双 ANN 物理信息模型则代表了另一条路径——用数据驱动或混合方法绕过部分物理复杂性。两种路径各有适用场景: 当物理机制清晰且参数可控时, 物理模型更可靠; 当物理机制过于复杂或参数难以测量时, 数据驱动方法提供了实用的替代方案。

GaN HEMT 因其高电子迁移率和高击穿场强, 在 5G 射频功率放大器(PA)中占据主导地位。其大信号建模的难点在于自热效应、陷阱诱导的电流崩塌、以及非线性输出电容的联合作用。Jarndal 等人^[15] 系统比较了三种智能建模方法: GA-ANN(遗传算法+ANN)、PSO-SVR(粒子群优化+支持向量回归)以及高斯过程回归(GPR)。他们发现, GA-ANN 成功解决了传统 BP-ANN 易陷入局部极小值的问题——GA 为 BP-ANN 提供了最优初始权重, 使得后续的梯度下降能够找到更好的解。三种方法的对比揭示了一个普遍规律: 优化器的选择与模型架构的选择同等重要。Xiang 等人^[34] 则将目光投向了极端环境——将 ANN 应用于 GaN HEMT 的低温(300 K 到 4.2 K)建模, 以支持量子计算等新兴应用。他们的 ANN 模型不仅捕获了 DC 和 RF 特性随温度、频率、偏置电压和器件尺寸的变化(精度超过 99%), 还成功用于 GaN MMIC 电路设计, 在 300 K 和 4.2 K 下与实测结果的平均相对误差均小于 4%。这一工作表明, ANN 的良好泛化能力使其特别适合“宽范围、多变量”的建模场景——这正是传统物理模型最吃力之处。Long 等人^[35] 则从电路应用角度切入, 针对 GaN HEMT 开关过电压问题, 提出了标准化的定量分析方法, 建立了考虑寄生参数的可靠电路模型。这与前两者形成互补: Jarndal 关注“模型怎么建”, Xiang 关注“模型能覆盖多宽的范围”, Long 关注“模型在电路中怎么

用”。

β -Ga₂O₃ 是超宽禁带半导体(禁带宽度约 4.8 eV), 其 Baliga 品质因数远高于 SiC 和 GaN, 在超高压器件领域潜力巨大。但它的“阿喀琉斯之踵”是极低的热导率——约为 SiC 的十分之一, 导致自热效应极为严重。这意味着, 忽略温度的模型在这类器件上几乎毫无意义。Zhou 等人^[36] 提出了基于表面势的 β -Ga₂O₃ MOSFET 电热紧凑模型, 在物理完整性上达到了新的高度: 用基于表面势的解析解描述电流, 用 Ward-Dutton 电荷划分方案计算端电荷, 用傅里叶热传导定律计算沟道温度, 并嵌入二阶 RC 热子电路耦合电热特性。模型与实验数据和 3D FEM 仿真进行了严格验证。更重要的是, 校准后的模型被用于评估衬底材料和厚度对 boost 转换器性能的影响——这恰恰是 DTCCO 所追求的目标: 在器件设计阶段就能评估其对电路性能的影响。

4.3 新兴存储器与特殊器件

与 SiC、GaN 等“有丰富物理先验”的器件不同, 新兴存储器和特殊器件往往面临另一个困境: 物理机制尚在探索中, 没有成熟的解析模型可供参考。这时, 数据驱动方法扮演了“快速启动”的角色。

Z²-FET 是基于 FD-SOI 技术的紧凑型器件, 利用带调制机制工作, 具有锐利开关和滞后特性, 在 1T-DRAM 和人工脉冲神经元方面有应用前景。然而, 其工作机制涉及带间隧穿、碰撞电离等多个复杂过程, 从头构建物理模型极为困难。Liu 等人^[37] 的解决方案颇具启发性: 他们将 Z²-FET 视为一个混合控制电压源, 用 ANN 直接学习输入(偏置电压)到输出(电流)的映射, 大大简化了建模过程。为捕获瞬态行为, 他们还基于独特的栅电荷存储效应和反馈机制建立了辅助 ANN(SA)。SPICE 仿真与 TCAD 吻合良好。这一工作的启示在于: 当物理机制过于复杂时, 暂时将其视为“黑箱”并用数据驱动方法建模, 可以快速获得可用的 SPICE 模型——这为新兴器件的早期设计探索提供了可能。

Xu 等人^[38] 选择了另一条路径。针对后端(BEOL)集成的独立双栅 a-IGZO 晶体管, 他们

没有完全依赖数据驱动,而是开发了基于表面势的物理紧凑模型,考虑了双栅耦合、无序输运、有限尺寸效应以及栅极对准偏差导致的寄生效应。该模型成功应用于无电容 DRAM 设计,展示了在单片 3D 集成中的潜力。与 Z^2 -FET 的“黑箱”策略相比, a-IGZO 的工作说明:即使在新兴器件上,如果物理机制足够清晰,物理模型仍然优先;只有在物理机制不清晰或过于复杂时,数据驱动才成为必要。

4.4 小结

从逻辑器件到功率器件再到新兴存储器, AI 辅助建模方法已经渗透到各类半导体器件的建模中。值得注意的趋势是:在成熟器件(如 SiC MOSFET)上,混合物理-数据方法更受青睐(因为已有丰富的物理先验知识);而在新兴器件(如 Z^2 -FET、 β -Ga₂O₃)上,纯数据驱动方法往往作为“快速启动”的手段,在物理模型成熟之前提供可用的 SPICE 模型。

5 模型验证与工业强度评估

实验室环境下的高精度拟合不足以证明一个模型适合工业应用。工业界对紧凑模型的要求远不止于低拟合误差,还包括物理正确性、数值鲁棒性、仿真效率等。

5.1 对称性、平滑性与渐近正确性

McAndrew [39] 讨论了一个物理正确的 MOSFET 模型必须在交换源漏电压时给出完全对称的电流和电荷响应。这听起来是基本要求,但许多 ANN 模型恰恰在这一关上栽了跟头——由于输入输出映射的非对称设计(例如将源极固定为参考节点),它们天然无法满足源漏对称性。对此, Pi-NN 和混合物理-ANN 方法的解决方案是:通过对称化输入(如同时输入 V_{ds} 和 V_{sd})或在损失函数中加入对称性惩罚项,来强制模型学习这一物理约束。另外,对于模拟电路设计而言,跨导(g_m)和输出电导(g_{ds})的平滑性比电流本身的精度更为重要——不光滑的

导数会直接导致仿真不收敛。然而,纯 ANN 模型由于激活函数和网络权重的离散性,容易在输出曲线上产生非物理的“波纹”或局部非单调行为。最后,一个好的模型不仅在训练数据覆盖的区域要准,在极限偏置条件下(如 V_{ds} 趋于 0 的线性区、 V_{gs} 远大于 V_{th} 的强反型饱和区)也必须趋近于理论渐近行为。

McAndrew 等人 [10] 进一步提出了针对 AI/ML 基 SPICE 模型的基准测试指南,强调必须评估以下方面:明确了四个必须评估的维度——物理正确性(是否满足热力学一致性等基本定律?)、平滑性/单调性(曲线及其导数是否光滑单调?)、渐近正确性(极限偏置下是否趋近理论行为?)以及数值鲁棒性(极端条件下是否收敛?)。并且呼吁 AI/ML 建模研究在报告拟合误差的同时,应系统评估上述工业级指标。

5.2 仿真速度对比

AI 模型的推理速度是其相对于传统物理模型的重要优势之一。Tung 等人 [40] 系统对比了 NN 模型与 BSIM-CMG 在 DC、AC、瞬态、RF 和噪声仿真中的速度。结果显示:在数字和模拟 IC 仿真中, NN 模型实现了显著加速。更进一步, Tung 等人 [41] 在 SISPAD 2024 上展示了 SPICE 兼容的 NN 紧凑模型,通过 Verilog-A 实现且使用直接乘法而非循环,在大型电路仿真中取得了约 40 倍于传统紧凑模型的速度提升。

Tung 等人 [42] 还开发了包含自热效应的 NN 模型,在宽温度范围内准确再现 I-V、C-V 和瞬态特性,相比 BSIM-CMG 实现了高达 12 倍的速度优势。其非准静态(NQS)扩展 [43] 进一步支持了瞬态、AC 和 RF 仿真,速度提升超过 14 倍。

5.3 变异性与可靠性建模

工艺波动导致的器件变异性是良率分析的关键。Dai 等人 [44] 提出了基于 ANN 的统计紧凑建模方法。核心思想是:保留标称器件的部分网络特征,然后微调变异性神经元(variational neurons)来再现静态变异。通过结合变异性神经元选择算法和方

差反向传播 (BPV) 方法, 建立了从工艺波动到网络参数的映射。该方法在 GAA 仿真数据和 16 nm FinFET 上得到验证。

5.4 行业标准兼容性

BSIM-NN 是 Tung 等人 [45] 提出的综合 NN 基紧凑模型, 涵盖了 IV、CV、几何与温度依赖性、自热、NQS 效应、变异性、寄生电容和噪声。模型用 NN 替代了工业标准 BSIM-CMG 的解析方程, 但保持了与 SPICE 的完全兼容, 并通过了 DC、AC、瞬态、RF 和噪声仿真的精度验证。这标志着 AI 紧凑模型已初步具备工业应用的技术基础。

6 挑战与未来方向

6.1 当前面临的主要挑战

尽管 AI 辅助器件建模取得了显著进展, 当前仍面临若干关键挑战。首先是物理一致性不足的问题。纯黑箱模型在超出训练范围时可能产生非物理解, 例如负电导或非单调输出电导。即便拟合误差很小, 这些非物理行为也可能导致电路仿真不收敛或结果错误 [10]。其次是数据效率低下的问题。高维工艺参数空间通常涉及十到二十个变量, 需要大量 TCAD 或测量数据才能充分覆盖。对于昂贵的新工艺节点或测量成本较高的器件, 如功率器件的高温测量, 数据获取往往成为瓶颈。第三, 缺乏工业级验证。目前大多数研究仍基于 TCAD 合成数据或少量实验室数据, 未在真实 PDK 开发流程中得到充分验证, McAndrew 等人 [10] 提出的基准测试指南尚未被广泛采纳。第四, 模型可解释性差。神经网络的“黑箱”特性使得工程师难以理解模型的预测依据, 也不便于指导器件物理的深入理解。最后, 异构器件覆盖不足。现有研究主要集中在硅基逻辑器件和 SiC/GaN 功率器件, 对于二维材料、有机半导体、量子器件等新兴领域的 AI 建模探索仍然有限。

6.2 未来研究方向

面向未来, 多个研究方向有望推动 AI 辅助器件建模走向成熟。在模型架构层面, Zhang 等人 [8] 提出的融合模型概念强调深度结合器件物理与神经网络, 而非简单的串行或并行组合。可能的实现方式包括将物理信息作为网络的正则化项 (如 PINN 路线), 让物理方程决定网络结构 (例如将表面势迭代求解过程展开为 RNN), 或将物理先验作为输入的预处理或输出的后处理。在数据利用方面, 数据高效学习策略显得尤为重要。主动学习可以智能选择信息量最大的仿真或测量点, 多保真度建模能够结合 TCAD、快速物理模型和实测等不同精度的数据源以降低高保真数据需求, 而迁移学习则可将从一个器件 (如大尺寸 SiC MOSFET) 学到的知识迁移到另一个器件 (如小尺寸或不同电压等级) 上。在设计技术协同优化 (DTCO) 中, AI 紧凑模型展现出独特优势。DTCO 要求在工艺开发早期就能评估设计选项对电路性能的影响, 而传统方法需要在 TCAD、紧凑模型、电路仿真之间多次迭代, 周期极长。AI 紧凑模型可以直接从 TCAD 仿真结果学习紧凑模型, 跳过人工参数提取步骤, 支持 “What-if” 快速评估, 并与贝叶斯优化等方法结合以自动搜索最优工艺-设计联合空间。此外, 可解释 AI (XAI) 在器件建模中的应用也值得关注。虽然神经网络内部是黑箱, 但 SHAP 值、注意力机制、概念激活向量等技术可以部分揭示模型的决策依据, 帮助工程师理解哪些输入参数对模型输出影响最大, 以及模型是否学习了正确的物理因果关系而非虚假关联。在多物理场与多尺度建模方面, PINN 框架天然支持电、热、力、光等多物理场耦合以及从原子尺度到器件尺度再到电路尺度的统一建模, 有望突破传统分层建模中不同尺度之间信息丢失的问题。最后, 全自动 PDK 生成是 AI 辅助建模的远景目标。结合 AI 参数提取、AI 模型验证和 AI 辅助文档生成, 未来有望实现输入 TCAD 校准数据和少量测量数据、输出可直接用于 SPICE 仿真的紧凑模型库, 从而大幅缩短新工艺节点的上市时间。

7 结论

半导体器件建模正经历从纯物理驱动向物理与数据双轮驱动的深刻范式转变。本文系统梳理了从 BSIM、EKV 等经典物理模型到 ANN、CNN、PINN 等智能模型的演进路径，并在统一框架下对比了各类方法的原理、优势与局限。

传统物理基模型（BSIM-CMG、EKV）奠定了工业基础，但面临参数提取复杂、可扩展性差、对新工艺响应慢等瓶颈。纯数据驱动模型（ANN、CNN、集成学习）在拟合精度和仿真速度上优势显著，但物理一致性差、外推不可靠，限制了其工业应用。物理-数据混合模型（Pi-NN、PINN、双 ANN 架构）通过引入物理约束，在保持数据驱动灵活性的同时提升了外推能力和导数平滑性，被认为是通往工业级 AI 紧凑模型的最有希望路径。参数提取自动化（DL 直接预测、全局提取、混合初始化）已证明可将参数提取时间从数周缩短至数小时，有望加速 PDK 开发流程。工业级验证需要超越拟合误差，评估对称性、渐近正确性、数值鲁棒性等指标——McAndrew 等人的基准指南^[10]为此提供了框架。未来方向包括融合模型、数据高效学习、DTCO 集成、可解释 AI、多物理场建模和全自动 PDK 生成。

可以预见，在未来的 5-10 年内，AI 辅助器件建模将从实验室探索走向工业大规模应用，成为支撑先进半导体技术持续演进的关键技术之一。

致谢 感谢审稿人和编辑部的辛勤工作。

参考文献

- Duarte J P, Khandelwal S, Medury A, et al. BSIM-CMG: Standard FinFET compact model for advanced circuit design. In: ESSCIRC Conference 2015. IEEE, 2015. 196-201
- 何进, 陈文新, 奚雪梅, 等. BSIM 模型的研究和最近进展. 半导体学报, 2006, 27(3): 388-396
- Enz C C, Krummenacher O, Vittoz E A. An analytical MOS transistor model valid in all regions of operation and dedicated to low-voltage and low-current applications. Analog Integr Circ S, 1995, 8(1): 83-114
- Vittoz E A, Enz C C. EKV Model of the MOS Transistor. In: Sub-threshold Design for Ultra Low-Power Systems. Springer US, 2007. 49-74
- Enz C C. A Short Story of the EKV MOS Transistor Model. IEEE Solid-State Circuits Society Newsletter, 2008, 13(3): 24-30
- Li X, Wu Z, Rzepa G, et al. Overview of emerging semiconductor device model methodologies: From device physics to machine learning engines. Fundamental Research, 2024, 4: 1-15
- Zhang L, Peng B, Li Y, et al. When Device Modeling Meets Machine Learning: Opportunities and Challenges (Invited). In: 2024 ACM/IEEE 6th Symposium on Machine Learning for CAD (MLCAD). IEEE, 2024. 1-6
- Zhang L, Chan M. Artificial neural network design for compact modeling of generic transistors. J Comput Electron, 2017, 16(3): 825-832
- Kao M Y, Kam H, Hu C. Deep-Learning-Assisted Physics-Driven MOSFET Current-Voltage Modeling. IEEE Electron Device Lett, 2022, 43(6): 974-977
- McAndrew C C, Scholten A J, Gullapalli K K, et al. Benchmarks for SPICE Modeling and Parameter Extraction Based on AI/ML. IEEE Trans Electron Devices, 2025, 72(4): 1551-1559
- Kraus R, Castellazzi A. A Physics-Based Compact Model of SiC Power MOSFETs. IEEE Trans Power Electron, 2016, 31(8): 5863-5870
- Pushpakaran B N, Bayne S B, Wang G, et al. Fast and accurate electro-thermal behavioral model of a commercial SiC 1200V, 80 mΩ power MOSFET. In: 2015 IEEE Pulsed Power Conference (PPC). IEEE, 2015. 1-5
- Mukunoki Y, Konno K, Matsuo T, et al. An Improved Compact Model for a Silicon-Carbide MOSFET and Its Application to Accurate Circuit Simulation. IEEE Trans Power Electron, 2018, 33(11): 9834-9842
- Mukunoki Y, Nakamura Y, Horiguchi T, et al. Characterization and Modeling of a 1.2-kV 30-A Silicon-Carbide MOSFET. IEEE Trans Electron Devices, 2016, 63(11): 4339-4345
- Jarndal A, Husain S, Hashmi M, et al. Large-Signal Modeling of GaN HEMTs Using Hybrid GA-ANN, PSO-SVR, and GPR-Based Approaches. IEEE J Electron Devices Soc, 2021, 9: 195-208
- Swain R, Jena K, Lenka T R. Modeling of Forward Gate Leakage Current in MOSHEMT Using Trap-Assisted Tunneling and Poole-Frenkel Emission. IEEE Trans Electron Devices, 2016, 63(6): 2346-2352
- Wang J, Kim Y H, Ryu J, et al. Artificial Neural Network-Based Compact Modeling Methodology for Ad-

- vanced Transistors. *IEEE Trans Electron Devices*, 2021, 68(3): 1318-1325
- 18 Wei J, Wang H, Zhao T, et al. A New Compact MOSFET Model Based on Artificial Neural Network With Unique Data Preprocessing and Sampling Techniques. *IEEE Trans Comput-Aided Des Integr Circuits Syst*, 2023, 42(4): 1250-1254
 - 19 Tung C T, Hu C. Neural Network-Based BSIM Transistor Model Framework: Currents, Charges, Variability, and Circuit Simulation. *IEEE Trans Electron Devices*, 2023, 70(4): 2157-2160
 - 20 Bavi D, Khandelwal S. Application of Residual Neural Network Towards Semiconductor Device Modeling. In: 2024 International Conference on Modeling, Simulation & Intelligent Computing (MoSiCom). IEEE, 2024. 190-195
 - 21 Zhang X, Chen S, Wang S, et al. Prediction of electrical properties of GAAFET based on integrated learning model. *Nanotechnology*, 2024, 35(31): 315705
 - 22 Li M, İrsoy O, Cardie C, et al. Physics-Inspired Neural Networks for Efficient Device Compact Modeling. *IEEE J Explor Solid-State Comput Devices Circuits*, 2016, 2: 44-49
 - 23 Lu A, Chau Y F, Wong H Y. Physics-Informed Neural Network for Predicting Out-of-Training-Range TCAD Solution with Minimized Domain Expertise. In: 2025 9th IEEE Electron Devices Technology & Manufacturing Conference (EDTM). IEEE, 2025. 1-3
 - 24 Yang W, Sun Y, Qi M, et al. A Physics-Informed Artificial Neural Network Modeling Approach for Wide Temperature Range 4H-SiC MOSFETs. In: 2023 International Conference on Sensing, Measurement & Data Analytics in the era of Artificial Intelligence (ICSMD). IEEE, 2023. 1-4
 - 25 Qi G, Chen X, Hu G, et al. Knowledge-based neural network SPICE modeling for MOSFETs and its application on 2D material field-effect transistors. *Sci China Inf Sci*, 2023, 66(2): 122405
 - 26 Kao M Y, Chavez F, Khandelwal S, et al. Deep Learning-Based BSIM-CMG Parameter Extraction for 10-nm FinFET. *IEEE Trans Electron Devices*, 2022, 69(8): 4765-4768
 - 27 Chavez F, Tung C T, Kao M Y, et al. Deep learning-based I-V Global Parameter Extraction for BSIM-CMG. *Solid-State Electron*, 2023, 209: 108766
 - 28 Singhal A, Pahwa G, Agarwal H. A Novel Physics Aware ANN-Based Framework for BSIM-CMG Model Parameter Extraction. *IEEE Trans Electron Devices*, 2024, 71(5): 3307-3314
 - 29 Guo G, Tang Z, Cui Z, et al. GatedNN: An accurate deep learning-based parameter extraction for BSIM-CMG. *Solid-State Electron*, 2025, 224: 109044
 - 30 Liu Y, Zhang W, Zhu Z, et al. DC model for SiC MOSFETs using artificial neural network optimized by artificial bee colony algorithm. *AIP Advances*, 2021, 11(11): 115219
 - 31 Jeong H, Choi J, Kim Y, et al. Efficient Neural Network-Based Compact Modeling for Novel Device Structures Using a Multi-Fidelity Model and Active Learning. *Electronics*, 2024, 13(23): 4840
 - 32 Ruihan L, Xingsheng W. Research on Efficient Extraction and Generation of Compact Models of Nanosheet Transistors. Master Thesis. Huazhong University of Science and Technology, 2023
 - 33 Arribas A P, Shang F, Krishnamurthy M, et al. Simple and Accurate Circuit Simulation Model for SiC Power MOSFETs. *IEEE Trans Electron Devices*, 2015, 62(2): 449-457
 - 34 Xiang Z, Zhang H, Zeng B, et al. Accurate Modeling of GaN HEMTs and MMICs for Cryogenic Electronics Applications Utilizing Artificial Neural Network. *IEEE J Emerg Sel Top Power Electron*, 2024, 12(6): 5661-5671
 - 35 Long X, Liang W, Jun Z, et al. A Normalized Quantitative Method for GaN HEMT Turn-ON Overvoltage Modeling and Suppressing. *IEEE Trans Ind Electron*, 2019, 66(4): 2766-2775
 - 36 Zhou K, Zhou X, He S, et al. A Physics-Based Compact Electrothermal Model of β -Ga₂O₃ MOSFETs for Device-Circuit Co-Design. *IEEE Trans Compon Packag Manuf Technol*, 2024, 14(12): 2231-2239
 - 37 Liu C, Chen Y, Cristoloveanu S, et al. A New Compact Z2-FET Model Based on Artificial Neural Network and Its Applications. *IEEE Trans Electron Devices*, 2024, 71(6): 3532-3539
 - 38 Xu L, Chen K, Li Z, et al. Physics-Based Compact Model of Independent Dual-Gate BEOL-Transistors for Reliable Capacitorless Memory. *IEEE J Electron Devices Soc*, 2024, 12: 359-364
 - 39 McAndrew C C. Validation of MOSFET model Source-Drain Symmetry. *IEEE Trans Electron Devices*, 2006, 53(9): 2202-2206
 - 40 Tung C T, Kao M Y, Hu C. Neural Network-Based and Modeling With High Accuracy and Potential Model Speed. *IEEE Trans Electron Devices*, 2022, 69(11): 6476-6479
 - 41 Tung C T, Salahuddin S, Hu C. A SPICE-Compatible Neural Network Compact Model for Efficient IC Simulations. In: 2024 International Conference on Simulation of

- Semiconductor Processes and Devices (SISPAD). IEEE, 2024. 1-4
- 42 Tung C T, Pampori A, Kumar Dabhi C, et al. A Novel Neural Network-Based Transistor Compact Model Including Self-Heating. IEEE Electron Device Lett, 2024, 45(8): 1512-1515
- 43 Tung C T, Salahuddin S, Hu C. Non-Quasi-Static Modeling of Neural Network-Based Transistor Compact Model for Fast Transient, AC, and RF Simulations. IEEE Electron Device Lett, 2024, 45(7): 1277-1280
- 44 Dai W, Li Y, Rong Z, et al. Statistical Compact Modeling With Artificial Neural Networks. IEEE Trans Comput-Aided Des Integr Circuits Syst, 2023, 42(12): 5156-5160
- 45 Tung C T, Salahuddin S, Hu C. BSIM-NN: A Machine Learning Compact Model for Fast IC Simulation. In: 2025 9th IEEE Electron Devices Technology & Manufacturing Conference (EDTM). IEEE, 2025. 1-3

From Physics-Driven to Intelligent Fusion in Semiconductor Device Modeling: A Review

Author A¹

1. Institute of Microelectronics, Chinese Academy of Sciences, Beijing 100029, China

As semiconductor technology nodes continuously scale down, conventional physics-based compact models face critical challenges including complex parameter extraction, poor scalability, and difficulties in modeling emerging physical effects. The rapid advancement of artificial intelligence (AI), particularly machine learning (ML), offers a new data-driven paradigm for device modeling. This paper systematically reviews the evolution from classical physical models such as BSIM and EKV to intelligent approaches including artificial neural networks (ANN), convolutional neural networks (CNN), physics-informed neural networks (PINN), and hybrid models. We focus on the current status and effectiveness of AI in automated parameter extraction, model surrogate, variability modeling, and design-technology co-optimization (DTCO). By comparing the accuracy, efficiency, physical consistency, and generalization capability of different methods, we reveal the respective strengths and limitations of pure data-driven and physics-integrated approaches. Finally, we outline future directions toward next-generation compact models that fuse physical priors with deep learning, and their potential applications across diverse scenarios from nanoscale logic to wide-bandgap power devices.

semiconductor devices, compact model, artificial intelligence, machine learning, physics-informed neural network, parameter extraction, DTCO

PACS: 85.30.-z, 84.30.-r, 07.05.Mh

doi: [10.1360/SSPMA-2026-XXXX](https://doi.org/10.1360/SSPMA-2026-XXXX)